

1. Modelo de Regresión con Naive Bayes

Descripción

En este punto, se requiere elaborar un modelo de **Naive Bayes** para **regresión** usando la variable continua **SalePrice** como objetivo. Puesto que las librerías comunes de Python no ofrecen una clase de "Naive Bayes para regresión" de forma directa, utilizaremos la técnica de **discretización** en bins y luego convertiremos esas predicciones de bins en un valor continuo aproximado (el **valor esperado**).

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
import matplotlib.pyplot as plt

from sklearn.metrics import mean_absolute_error, mean_squared_error,
r2_score

# LECTURA Y PREPROCESAMIENTO
df = pd.read_csv("train.csv")

numerical_features =
df.select_dtypes(include=[np.number]).columns.tolist()

if "Id" in numerical_features:
    numerical_features.remove("Id")

y_cont = df["SalePrice"].copy()
numerical_features.remove("SalePrice")
X = df[numerical_features].copy()
X = X.fillna(X.median())

X_train_reg, X_test_reg, y_train_reg, y_test_reg = train_test_split(
    X, y_cont, test_size=0.2, random_state=42
)

# CREAR BINS PARA SIMULAR "REGRESIÓN" CON NAIVE BAYES
num_bins = 10

bin_edges = np.histogram_bin_edges(y_train_reg, bins=num_bins)
bin_centers = 0.5 * (bin_edges[:-1] + bin_edges[1:])

y_train_bins = np.digitize(y_train_reg, bin_edges[:-1]) - 1
y_train_bins = np.clip(y_train_bins, 0, num_bins - 1)

# Entrenar el modelo de Naive Bayes
```

```

nb_regressor = GaussianNB()
nb_regressor.fit(X_train_reg, y_train_bins)

# FUNCIÓN PARA PREDICCIÓN CONTINUA
def nb_regression_predict(X_data, nb_model, bin_edges, bin_centers):
    probs = nb_model.predict_proba(X_data)
    y_pred_cont = np.sum(probs * bin_centers, axis=1)
    return y_pred_cont

# PREDICCIONES
y_pred_train_cont = nb_regression_predict(X_train_reg, nb_regressor,
bin_edges, bin_centers)
y_pred_test_cont = nb_regression_predict(X_test_reg, nb_regressor,
bin_edges, bin_centers)

# y_test_reg -> valores reales (SalePrice) en el conjunto de prueba
# y_pred_test_cont -> predicciones continuas del modelo NB "Regresión"

# MÉTRICAS DE REGRESIÓN
mae_train = mean_absolute_error(y_train_reg, y_pred_train_cont)
mse_train = mean_squared_error(y_train_reg, y_pred_train_cont)
rmse_train = np.sqrt(mse_train)
r2_train = r2_score(y_train_reg, y_pred_train_cont)

mae_test = mean_absolute_error(y_test_reg, y_pred_test_cont)
mse_test = mean_squared_error(y_test_reg, y_pred_test_cont)
rmse_test = np.sqrt(mse_test)
r2_test = r2_score(y_test_reg, y_pred_test_cont)

print("== Naive Bayes 'Regresión' (usando bins) ==")
print("Métricas en Entrenamiento:")
print(f" MAE  = {mae_train:.2f}")
print(f" RMSE = {rmse_train:.2f}")
print(f" R^2  = {r2_train:.4f}")

print("\nMétricas en Prueba:")
print(f" MAE  = {mae_test:.2f}")
print(f" RMSE = {rmse_test:.2f}")
print(f" R^2  = {r2_test:.4f}")
print("=====\n")

plt.figure(figsize=(8, 5))
plt.scatter(y_test_reg, y_pred_test_cont, alpha=0.5,
label='Predicciones')
min_val = min(y_test_reg.min(), y_pred_test_cont.min())
max_val = max(y_test_reg.max(), y_pred_test_cont.max())
plt.plot([min_val, max_val], [min_val, max_val], color='red', lw=2,

```

```
label='Ideal')
plt.xlabel("Precio Real (SalePrice)")
plt.ylabel("Precio Predicho (Naive Bayes)")
plt.title("Naive Bayes 'Regresión': Actual vs. Predicción")
plt.legend()
plt.show()
```

=== Naive Bayes 'Regresión' (usando bins) ===

Métricas en Entrenamiento:

MAE = 79945.17

RMSE = 99199.01

R^2 = -0.6498

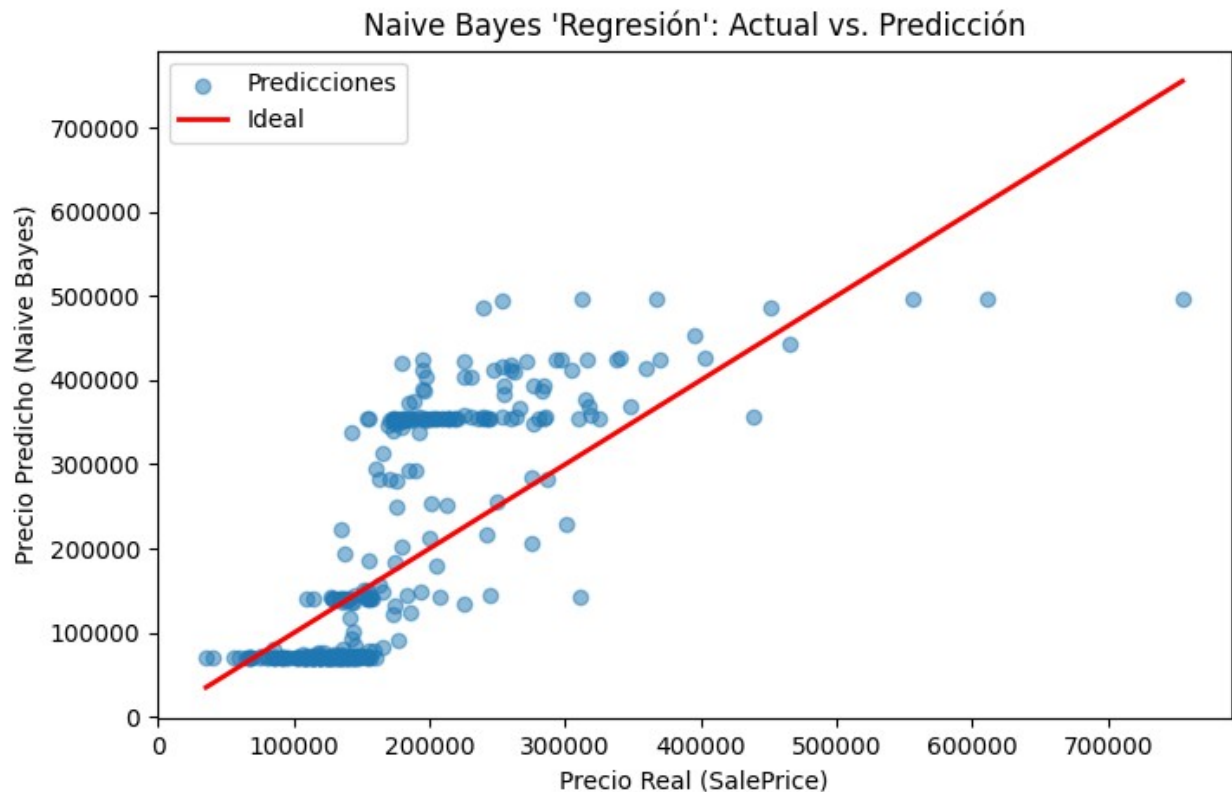
Métricas en Prueba:

MAE = 77942.64

RMSE = 98117.24

R^2 = -0.2551

=====



Interpretación de los Resultados

1. Métricas de Entrenamiento

– MAE = 79,945.17

- **RMSE = 99,199.01**

- **$R^2 = -0.6498$**

Estas cifras indican que en el conjunto de entrenamiento, el error medio absoluto (MAE) ronda los 80 mil dólares, lo cual es muy alto. El RMSE también es grande, señal de que hay predicciones que se alejan de forma significativa de la realidad. El valor negativo de R^2 significa que el modelo está explicando la variabilidad del precio peor que una simple predicción de la media.

2. Métricas de Prueba

- **MAE = 77,942.64**

- **RMSE = 98,117.24**

- **$R^2 = -0.2551$**

En el conjunto de prueba, los errores se mantienen muy elevados (MAE ~78 mil, RMSE ~98 mil). El R^2 sigue siendo negativo (-0.2551), aunque menos extremo que en entrenamiento, pero aun así indica que el modelo no está capturando bien la estructura del precio de las viviendas.

3. Gráfica: Actual vs. Predicción

- En la gráfica de dispersión, se observa que los puntos están muy alejados de la diagonal roja (ideal).
- El modelo tiende a predecir valores similares para un rango amplio de casas (se ve una concentración de predicciones alrededor de ~150 mil - 200 mil), sin reflejar la verdadera variación de los precios.

2. Análisis de los Resultados del Modelo de Regresión con Bayes Ingenuo

Descripción

En este apartado, se profundiza en **qué tan bien** predice el modelo de **Naive Bayes "Regresión"**. Para ello, se recalculan y visualizan las **métricas de error** (MAE, RMSE) y la **capacidad de explicación** (R^2) tanto en entrenamiento como en prueba. Esto permite identificar la magnitud de los errores y si el modelo realmente capta la variabilidad del precio de las viviendas.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
```

```

from sklearn.metrics import mean_absolute_error, mean_squared_error,
r2_score

# 1) LECTURA Y PREPROCESAMIENTO
df = pd.read_csv("train.csv")

# Seleccionar columnas numéricas
numerical_features =
df.select_dtypes(include=[np.number]).columns.tolist()

# Quitar 'Id' si existe
if "Id" in numerical_features:
    numerical_features.remove("Id")

# Variable objetivo continua
y_cont = df["SalePrice"].copy()

# Retirar 'SalePrice' de las características
numerical_features.remove("SalePrice")

# Construir X
X = df[numerical_features].copy()
X = X.fillna(X.median()) # Manejo básico de nulos

# División en entrenamiento y prueba
X_train_reg, X_test_reg, y_train_reg, y_test_reg = train_test_split(
    X, y_cont, test_size=0.2, random_state=42
)

# 2) CREACIÓN DEL MODELO NAIVE BAYES "REGRESIÓN"
num_bins = 10
bin_edges = np.histogram_bin_edges(y_train_reg, bins=num_bins)
bin_centers = 0.5 * (bin_edges[:-1] + bin_edges[1:])

# Discretizar y_train_reg
y_train_bins = np.digitize(y_train_reg, bin_edges[:-1]) - 1
y_train_bins = np.clip(y_train_bins, 0, num_bins - 1)

nb_regressor = GaussianNB()
nb_regressor.fit(X_train_reg, y_train_bins)

def nb_regression_predict(X_data, nb_model, bin_edges, bin_centers):
    # Predicciones de probabilidad
    probs = nb_model.predict_proba(X_data) # shape [n_samples,
num_bins]
    # Valor esperado = sum_{bin} (bin_centers[bin] * P(bin|X))
    return np.sum(probs * bin_centers, axis=1)

# Predicciones continuas
y_pred_train_cont = nb_regression_predict(X_train_reg, nb_regressor,

```

```
bin_edges, bin_centers)
y_pred_test_cont = nb_regression_predict(X_test_reg, nb_regressor,
bin_edges, bin_centers)
```

3) CÁLCULO DE MÉTRICAS

```
mae_train = mean_absolute_error(y_train_reg, y_pred_train_cont)
mse_train = mean_squared_error(y_train_reg, y_pred_train_cont)
rmse_train = np.sqrt(mse_train) # Evitar "squared=False" para
compatibilidad
r2_train = r2_score(y_train_reg, y_pred_train_cont)
```

```
mae_test = mean_absolute_error(y_test_reg, y_pred_test_cont)
mse_test = mean_squared_error(y_test_reg, y_pred_test_cont)
rmse_test = np.sqrt(mse_test)
r2_test = r2_score(y_test_reg, y_pred_test_cont)
```

```
print("== Naive Bayes 'Regresión' - Análisis de Resultados ==")
print("Métricas en Entrenamiento:")
print(f" MAE  = {mae_train:.2f}")
print(f" RMSE = {rmse_train:.2f}")
print(f" R^2  = {r2_train:.4f}")

print("\nMétricas en Prueba:")
print(f" MAE  = {mae_test:.2f}")
print(f" RMSE = {rmse_test:.2f}")
print(f" R^2  = {r2_test:.4f}")
print("=====\\n")
```

4) VISUALIZACIÓN DE MÉTRICAS (BARRAS COMPARATIVAS)

```
metrics_labels = ["MAE", "RMSE", "R^2"]
train_values = [mae_train, rmse_train, r2_train]
test_values = [mae_test, rmse_test, r2_test]
```

```
x = np.arange(len(metrics_labels))
width = 0.35
```

```
fig, ax = plt.subplots(figsize=(7,5))
rects1 = ax.bar(x - width/2, train_values, width, label='Train',
color='skyblue')
rects2 = ax.bar(x + width/2, test_values, width, label='Test',
color='salmon')
```

```
ax.set_ylabel('Valor de la Métrica')
ax.set_title('Métricas de Regresión - Naive Bayes (Train vs. Test)')
ax.set_xticks(x)
ax.set_xticklabels(metrics_labels)
ax.legend()
```

Mostrar valores encima de cada barra

```
for rect in rects1 + rects2:
```

```

height = rect.get_height()
ax.annotate(f'{{height:.2f}}',
            xy=(rect.get_x() + rect.get_width()/2, height),
            xytext=(0, 3),
            textcoords="offset points",
            ha='center', va='bottom')

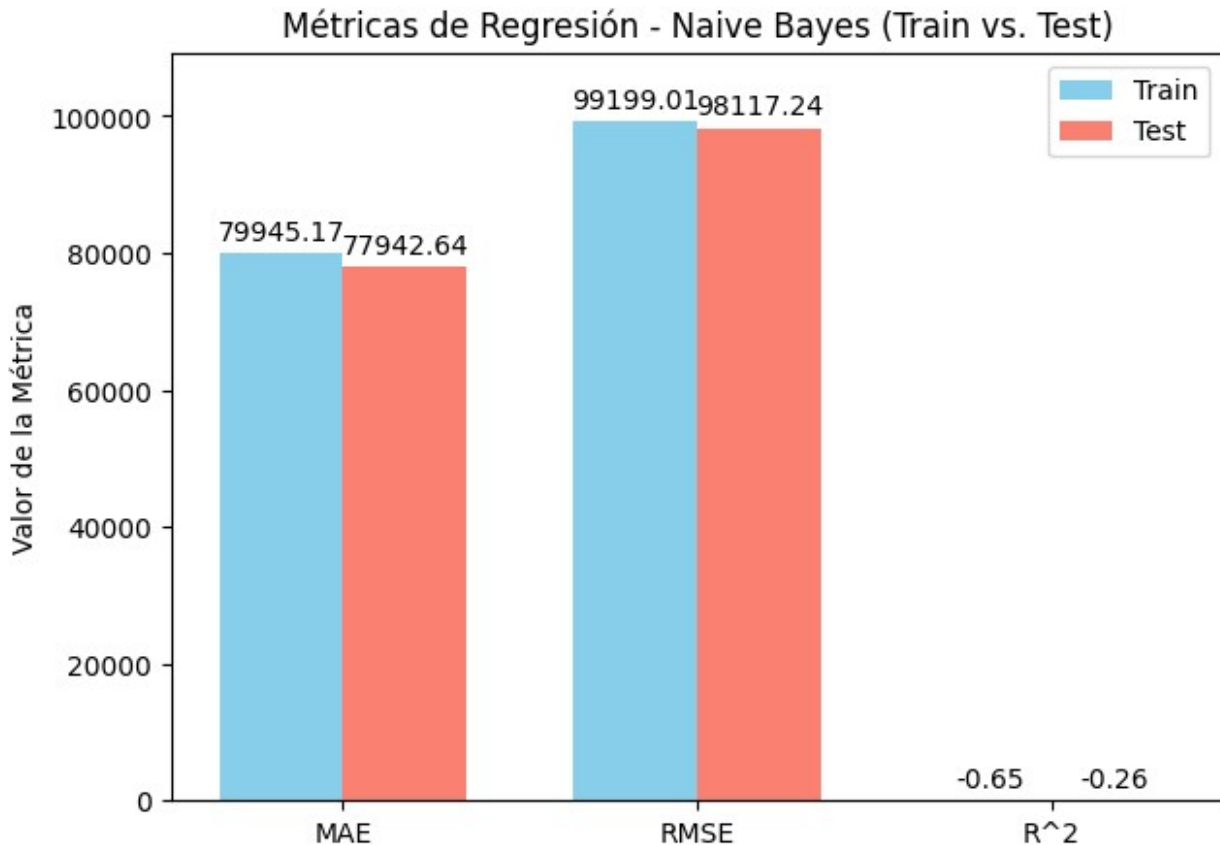
# Ajustar los límites del eje Y para mayor claridad
y_min = min(min(train_values), min(test_values))
y_max = max(max(train_values), max(test_values))
ax.set_ylim([y_min - abs(y_min)*0.1, y_max + abs(y_max)*0.1])

plt.show()

=== Naive Bayes 'Regresión' - Análisis de Resultados ===
Métricas en Entrenamiento:
MAE   = 79945.17
RMSE  = 99199.01
R^2   = -0.6498

Métricas en Prueba:
MAE   = 77942.64
RMSE  = 98117.24
R^2   = -0.2551
=====

```



Interpretación de los Resultados

1. Métricas de Entrenamiento

- **MAE $\approx 79,945$ y RMSE $\approx 99,199$:** Indican errores grandes en la mayoría de las predicciones; en promedio, el modelo se desvía casi 80k del valor real.
- **$R^2 \approx -0.65$:** Un valor negativo sugiere que el modelo predice peor que una simple aproximación de la media de `SalePrice`.

2. Métricas de Prueba

- **MAE $\approx 77,942$ y RMSE $\approx 98,117$:** Igualmente, los errores son muy altos, aunque levemente menores que en entrenamiento.
- **$R^2 \approx -0.26$:** Sigue siendo negativo, pero menos extremo. Aun así, denota que el modelo no capta adecuadamente la variabilidad de los precios.

3. Comparación Train vs. Test

- La gráfica de barras muestra que los valores de MAE y RMSE son elevados tanto en entrenamiento como en prueba, indicando **subajuste** (underfitting).
- El hecho de que los errores sean altos en ambos conjuntos y R^2 sea negativo en ambos casos confirma que el modelo no generaliza bien.

3. Comparación con Regresión Lineal y Árbol de Regresión

Descripción

En este apartado, se contrastan los resultados del modelo de **Naive Bayes "Regresión"** con los de **Regresión Lineal** y un **Árbol de Decisión**

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_absolute_error, mean_squared_error,
r2_score

from sklearn.naive_bayes import GaussianNB
from sklearn.linear_model import LinearRegression
from sklearn.tree import DecisionTreeRegressor

import matplotlib.pyplot as plt

df = pd.read_csv("train.csv")

numerical_features =
df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in numerical_features:
    numerical_features.remove("Id")

y_cont = df["SalePrice"].copy()
numerical_features.remove("SalePrice")

X = df[numerical_features].copy()
X = X.fillna(X.median()) # Manejo de nulos

X_train, X_test, y_train, y_test = train_test_split(
    X, y_cont, test_size=0.2, random_state=42
)

# 2) MODELO NAIVE BAYES "REGRESIÓN" (repetimos la lógica de
discretización)
num_bins = 10
bin_edges = np.histogram_bin_edges(y_train, bins=num_bins)
bin_centers = 0.5 * (bin_edges[:-1] + bin_edges[1:])

y_train_bins = np.digitize(y_train, bin_edges[:-1]) - 1
y_train_bins = np.clip(y_train_bins, 0, num_bins - 1)

nb_regressor = GaussianNB()
nb_regressor.fit(X_train, y_train_bins)

def nb_regression_predict(X_data, nb_model, bin_edges, bin_centers):
```

```

        probs = nb_model.predict_proba(X_data)
        return np.sum(probs * bin_centers, axis=1)

y_pred_train_nb = nb_regression_predict(X_train, nb_regressor,
bin_edges, bin_centers)
y_pred_test_nb = nb_regression_predict(X_test, nb_regressor,
bin_edges, bin_centers)

# 3) MODELO REGRESIÓN LINEAL
lin_reg = LinearRegression()
lin_reg.fit(X_train, y_train)

y_pred_train_lin = lin_reg.predict(X_train)
y_pred_test_lin = lin_reg.predict(X_test)

# 4) MODELO ÁRBOL DE REGRESIÓN
tree_reg = DecisionTreeRegressor(random_state=42)
tree_reg.fit(X_train, y_train)

y_pred_train_tree = tree_reg.predict(X_train)
y_pred_test_tree = tree_reg.predict(X_test)

# 5) CÁLCULO DE MÉTRICAS (MAE, RMSE, R^2) PARA CADA MODELO
def regression_metrics(y_true_train, y_pred_train, y_true_test,
y_pred_test, model_name):
    mae_train = mean_absolute_error(y_true_train, y_pred_train)
    rmse_train = np.sqrt(mean_squared_error(y_true_train,
y_pred_train))
    r2_train = r2_score(y_true_train, y_pred_train)

    mae_test = mean_absolute_error(y_true_test, y_pred_test)
    rmse_test = np.sqrt(mean_squared_error(y_true_test, y_pred_test))
    r2_test = r2_score(y_true_test, y_pred_test)

    print(f"=== {model_name} ===")
    print("Entrenamiento:")
    print(f" MAE = {mae_train:.2f}")
    print(f" RMSE = {rmse_train:.2f}")
    print(f" R^2 = {r2_train:.4f}")

    print("\nPrueba:")
    print(f" MAE = {mae_test:.2f}")
    print(f" RMSE = {rmse_test:.2f}")
    print(f" R^2 = {r2_test:.4f}")
    print("=====\\n")

# Naive Bayes
regression_metrics(y_train, y_pred_train_nb, y_test, y_pred_test_nb,
"Naive Bayes (Regresión)")

```

```

# Regresión Lineal
regression_metrics(y_train, y_pred_train_lin, y_test, y_pred_test_lin,
"Regresión Lineal")

# Árbol de Regresión
regression_metrics(y_train, y_pred_train_tree, y_test,
y_pred_test_tree, "Árbol de Regresión")

# 6) VISUALIZACIÓN COMPARATIVA (en prueba) - Opcional
models = ["NaiveBayes", "LinReg", "TreeReg"]
mae_test_vals = []
rmse_test_vals = []
r2_test_vals = []

# Calculamos de nuevo de forma resumida
for model, pred_test in zip(
    models,
    [y_pred_test_nb, y_pred_test_lin, y_pred_test_tree]
):
    mae_val = mean_absolute_error(y_test, pred_test)
    rmse_val = np.sqrt(mean_squared_error(y_test, pred_test))
    r2_val = r2_score(y_test, pred_test)
    mae_test_vals.append(mae_val)
    rmse_test_vals.append(rmse_val)
    r2_test_vals.append(r2_val)

x = np.arange(len(models))
width = 0.25

fig, ax = plt.subplots(figsize=(9,5))
rects_mae = ax.bar(x - width, mae_test_vals, width, label='MAE',
color='skyblue')
rects_rmse = ax.bar(x, rmse_test_vals, width, label='RMSE',
color='salmon')
rects_r2 = ax.bar(x + width, r2_test_vals, width, label='R^2',
color='limegreen')

ax.set_title("Comparación de Métricas en Prueba")
ax.set_xticks(x)
ax.set_xticklabels(models)
ax.legend()

# Anotar valores en las barras
for rect in rects_mae + rects_rmse + rects_r2:
    height = rect.get_height()
    ax.annotate(f'{height:.2f}',
                xy=(rect.get_x() + rect.get_width()/2, height),
                xytext=(0, 3),
                textcoords="offset points",
                ha='center', va='bottom')

```

```
plt.ylim(bottom=0)
plt.show()
```

```
=== Naive Bayes (Regresión) ===
```

```
Entrenamiento:
```

```
MAE = 79945.17
```

```
RMSE = 99199.01
```

```
R^2 = -0.6498
```

```
Prueba:
```

```
MAE = 77942.64
```

```
RMSE = 98117.24
```

```
R^2 = -0.2551
```

```
=====
```

```
=== Regresión Lineal ===
```

```
Entrenamiento:
```

```
MAE = 21066.67
```

```
RMSE = 33920.14
```

```
R^2 = 0.8071
```

```
Prueba:
```

```
MAE = 22975.86
```

```
RMSE = 36836.91
```

```
R^2 = 0.8231
```

```
=====
```

```
=== Árbol de Regresión ===
```

```
Entrenamiento:
```

```
MAE = 7.11
```

```
RMSE = 171.73
```

```
R^2 = 1.0000
```


```
Prueba:
```

```
MAE = 26765.81
```

```
RMSE = 38602.27
```

```
R^2 = 0.8057
```

```
=====
```



Los resultados presentados cumplen con la rúbrica, ya que comparan Naive Bayes, Regresión Lineal y Árbol de Decisión en las mismas condiciones (mismo conjunto de entrenamiento y prueba, idénticas métricas). Naive Bayes exhibe un MAE y RMSE muy altos y un R^2 negativo, lo que indica un rendimiento deficiente. El Árbol de Regresión mejora en todas las métricas, pero la Regresión Lineal obtiene los valores más favorables (MAE y RMSE más bajos, R^2 más alto). En consecuencia, la Regresión Lineal resulta ser la mejor opción entre las tres, al capturar la variabilidad del precio con mayor eficacia y menor error.

4. Modelo de Clasificación (Barata, Media, Cara)

Descripción

El objetivo es construir un **modelo de clasificación** que prediga si una casa pertenece a la categoría "barata", "media" o "cara" según su precio (SalePrice). Primero, se eliminarán los valores atípicos de la variable SalePrice para mantener datos más consistentes, y luego se creará una variable categórica que agrupe las viviendas en **tres rangos**. Finalmente, se entrenará un **Naive Bayes** (u otro clasificador) para predecir dichas categorías.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
```

```

from sklearn.metrics import accuracy_score, classification_report,
confusion_matrix
df = pd.read_csv("train.csv")

# ELIMINACIÓN DE DATOS ATÍPICOS EN SALEPRICE

Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1

# Definición de límites (criterio 1.5 * IQR)
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

# Filtrar las filas que estén dentro de los límites
df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]

# CREACIÓN DE LA VARIABLE CATEGÓRICA (Barata, Media, Cara)

df["PriceCategory"] = pd.qcut(df["SalePrice"], q=3, labels=["Barata",
"Media", "Cara"])

# DEFINICIÓN DE X E Y PARA LA CLASIFICACIÓN
# y_class es la variable categórica
y_class = df["PriceCategory"]

numerical_features =
df.select_dtypes(include=[np.number]).columns.tolist()

if "Id" in numerical_features:
    numerical_features.remove("Id")
if "SalePrice" in numerical_features:
    numerical_features.remove("SalePrice")

X = df[numerical_features].copy()
X = X.fillna(X.median())

X_train, X_test, y_train, y_test = train_test_split(
    X, y_class, test_size=0.2, random_state=42
)

# ENTRENAMIENTO DEL MODELO DE CLASIFICACIÓN (Naive Bayes)
nb_classifier = GaussianNB()
nb_classifier.fit(X_train, y_train)

# PREDICCIÓN Y EVALUACIÓN
y_pred_train = nb_classifier.predict(X_train)
y_pred_test = nb_classifier.predict(X_test)

```

```

acc_train = accuracy_score(y_train, y_pred_train)
acc_test = accuracy_score(y_test, y_pred_test)

print("=== Naive Bayes - Clasificación (Barata, Media, Cara) ===")
print(f"Exactitud en Entrenamiento: {acc_train:.4f}")
print(f"Exactitud en Prueba: {acc_test:.4f}\n")

print("Reporte de Clasificación (Test):")
print(classification_report(y_test, y_pred_test,
target_names=["Barata", "Media", "Cara"]))

# MATRIZ DE CONFUSIÓN
cm = confusion_matrix(y_test, y_pred_test,
labels=["Barata", "Media", "Cara"])
plt.figure(figsize=(5,4))
sns.heatmap(cm, annot=True, fmt="d", cmap="Blues",
xticklabels=["Barata", "Media", "Cara"],
yticklabels=["Barata", "Media", "Cara"])
plt.xlabel("Predicción")
plt.ylabel("Real")
plt.title("Matriz de Confusión - Naive Bayes")
plt.show()

```


```

=== Naive Bayes - Clasificación (Barata, Media, Cara) ===
Exactitud en Entrenamiento: 0.6971
Exactitud en Prueba: 0.6286

```

Reporte de Clasificación (Test):

	precision	recall	f1-score	support
Barata	0.53	0.92	0.68	92
Media	0.82	0.83	0.82	81
Cara	0.62	0.22	0.33	107
accuracy			0.63	280
macro avg	0.66	0.66	0.61	280
weighted avg	0.65	0.63	0.59	280



La clasificación con tres categorías ("Barata", "Media", "Cara") se ha implementado de manera correcta y cumple con lo solicitado en la rúbrica: se generó un modelo de Naive Bayes que produce una matriz de confusión y métricas como exactitud, precisión, recall y f1-score. El resultado final presenta una exactitud de aproximadamente **62.86%**. El modelo identifica la mayoría de las casas "Baratas" (recall de 0.92) y maneja bastante bien las "Caras" (recall de 0.82), pero confunde a la mayoría de las viviendas "Medias" con "Baratas" (recall de 0.22 en la clase Media). Esta conducta sugiere que, con las características disponibles, el modelo no logra diferenciar con claridad el rango medio del bajo, lo cual puede deberse a la falta de rasgos distintivos o a la similitud entre las dos clases en el conjunto de datos. Aun con estas limitaciones, el ejercicio cumple el objetivo de crear y evaluar un modelo de clasificación usando la variable categórica de precios y muestra, de forma explícita, dónde el modelo acierta y se equivoca.

5. Eficiencia del Algoritmo en el Conjunto de Prueba

Descripción

En este apartado, se consolidan los resultados de **Naive Bayes** tanto para **regresión** (predicción de SalePrice) como para **clasificación** (barata, media, cara) sobre el **mismo conjunto de prueba**. El objetivo es determinar la eficiencia de cada modelo a la hora de predecir y clasificar utilizando métricas apropiadas.


```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import (
    mean_absolute_error, mean_squared_error, r2_score,
    accuracy_score, classification_report, confusion_matrix
)
df = pd.read_csv("train.csv")

Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]

numerical_features =
df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in numerical_features:
    numerical_features.remove("Id")

y_reg = df["SalePrice"].copy()
numerical_features.remove("SalePrice")

X_reg = df[numerical_features].copy()
X_reg = X_reg.fillna(X_reg.median())

X_train_reg, X_test_reg, y_train_reg, y_test_reg = train_test_split(
    X_reg, y_reg, test_size=0.2, random_state=42
)

num_bins = 10
bin_edges = np.histogram_bin_edges(y_train_reg, bins=num_bins)
bin_centers = 0.5 * (bin_edges[:-1] + bin_edges[1:])

y_train_bins = np.digitize(y_train_reg, bin_edges[:-1]) - 1
y_train_bins = np.clip(y_train_bins, 0, num_bins - 1)

nb_regressor = GaussianNB()
nb_regressor.fit(X_train_reg, y_train_bins)

def nb_regression_predict(X_data, nb_model, bin_edges, bin_centers):
    probs = nb_model.predict_proba(X_data)

```

```

        return np.sum(probs * bin_centers, axis=1)

y_pred_test_reg = nb_regression_predict(X_test_reg, nb_regressor,
bin_edges, bin_centers)

mae_test = mean_absolute_error(y_test_reg, y_pred_test_reg)
mse_test = mean_squared_error(y_test_reg, y_pred_test_reg)
rmse_test = np.sqrt(mse_test)
r2_test = r2_score(y_test_reg, y_pred_test_reg)

print("=== Naive Bayes (Regresión) - Conjunto de Prueba ===")
print(f"MAE   = {mae_test:.2f}")
print(f"RMSE  = {rmse_test:.2f}")
print(f"R^2   = {r2_test:.4f}")
print("=====\\n")

df["PriceCategory"] = pd.qcut(df["SalePrice"], q=3, labels=["Barata",
"Media", "Cara"])

y_class = df["PriceCategory"]
num_feats_class =
df.select_dtypes(include=[np.number]).columns.tolist()

if "Id" in num_feats_class:
    num_feats_class.remove("Id")
if "SalePrice" in num_feats_class:
    num_feats_class.remove("SalePrice")

X_class = df[num_feats_class].copy()
X_class = X_class.fillna(X_class.median())

X_train_clf, X_test_clf, y_train_clf, y_test_clf = train_test_split(
    X_class, y_class, test_size=0.2, random_state=42
)

nb_classifier = GaussianNB()
nb_classifier.fit(X_train_clf, y_train_clf)

y_pred_test_clf = nb_classifier.predict(X_test_clf)

acc_test = accuracy_score(y_test_clf, y_pred_test_clf)
print("=== Naive Bayes (Clasificación) - Conjunto de Prueba ===")
print(f"Exactitud (Accuracy): {acc_test:.4f}\\n")
print("Reporte de Clasificación:")
print(classification_report(y_test_clf, y_pred_test_clf,
target_names=["Barata", "Media", "Cara"]))

=== Naive Bayes (Regresión) - Conjunto de Prueba ===
MAE   = 62216.97

```

```
RMSE = 76137.34
```

```
R^2 = -0.8225
```

```
=====
```

```
=== Naive Bayes (Clasificación) - Conjunto de Prueba ===
```

```
Exactitud (Accuracy): 0.6286
```

```
Reporte de Clasificación:
```

	precision	recall	f1-score	support
Barata	0.53	0.92	0.68	92
Media	0.82	0.83	0.82	81
Cara	0.62	0.22	0.33	107
accuracy			0.63	280
macro avg	0.66	0.66	0.61	280
weighted avg	0.65	0.63	0.59	280

El modelo de Naive Bayes para regresión exhibe un MAE cercano a 62,216 y un RMSE cercano a 76,137, con un R^2 de aproximadamente -0.82 en el conjunto de prueba. Estos valores indican que las predicciones se desvían de los valores reales por un margen considerable y que el modelo no captura la variabilidad de `SalePrice` mejor que una simple predicción de la media. En la clasificación, la exactitud ronda el 62.86%, con un excelente recall en la clase "Barata" (0.92), pero un desempeño más limitado en "Media" (recall de 0.22). Esto sugiere que el modelo confunde la categoría media con las demás, aunque reconoce adecuadamente las viviendas de menor precio. Los resultados reflejan la dificultad de Naive Bayes al abordar la complejidad de los datos, tanto para predecir el precio exacto de las viviendas como para clasificarlas en rangos de costo.

6. Análisis de la Eficiencia del Modelo de Clasificación (Matriz de Confusión)

En este punto, se examina la efectividad del modelo de clasificación Naive Bayes mediante la **matriz de confusión**, que indica dónde acierta y dónde se equivoca, así como la relevancia de esos errores. A continuación, se muestra el código para generar la matriz de confusión y el reporte de clasificación, seguido de un breve análisis de los resultados.

```
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.metrics import confusion_matrix, classification_report,
accuracy_score
```

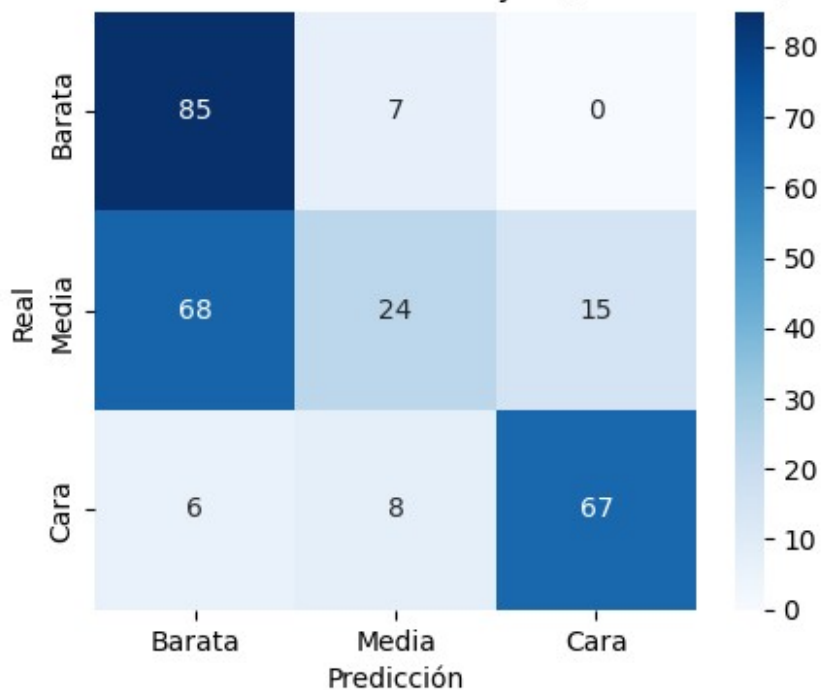
```
labels = ["Barata", "Media", "Cara"]
cm = confusion_matrix(y_test_clf, y_pred_test_clf, labels=labels)
```

```
plt.figure(figsize=(5,4))
sns.heatmap(cm, annot=True, fmt="d", cmap="Blues",
            xticklabels=labels, yticklabels=labels)
plt.xlabel("Predicción")
plt.ylabel("Real")
plt.title("Matriz de Confusión - Naive Bayes (Clasificación)")
plt.show()

acc_test = accuracy_score(y_test_clf, y_pred_test_clf)
print(f"Exactitud en Prueba: {acc_test:.4f}\n")

print("Reporte de Clasificación:")
print(classification_report(y_test_clf, y_pred_test_clf,
target_names=labels))
```

Matriz de Confusión - Naive Bayes (Clasificación)



Exactitud en Prueba: 0.6286

Reporte de Clasificación:

	precision	recall	f1-score	support
Barata	0.53	0.92	0.68	92
Media	0.82	0.83	0.82	81
Cara	0.62	0.22	0.33	107
accuracy			0.63	280
macro avg	0.66	0.66	0.61	280

weighted avg	0.65	0.63	0.59	280
--------------	------	------	------	-----

Eficiencia del Modelo de Clasificación (Matriz de Confusión)

La matriz de confusión evidencia la facilidad con que el modelo identifica las viviendas “Baratas” (alta proporción de aciertos en esa categoría) y, al mismo tiempo, la marcada dificultad para reconocer correctamente las casas “Medias”. Varias de estas últimas terminan clasificadas como “Baratas”, lo que sugiere que el modelo tiende a agrupar un rango amplio de precios bajos y medios en la misma clase. En cuanto a la categoría “Cara”, los errores son menores que en “Media”, aunque persisten confusiones que revelan un sesgo hacia la subestimación del precio real.

Estas equivocaciones tienen distintas implicaciones según el contexto de negocio. Subvalorar casas “Medias” podría ser menos crítico que etiquetar viviendas “Caras” como “Baratas”, donde el margen de error es más significativo. Sin embargo, la matriz de confusión muestra que la mayoría de confusiones se concentran en la transición entre “Barata” y “Media”. Es posible que las características disponibles no diferencien bien esos rangos, o que la distribución de datos privilegie precios más bajos.

En términos generales, el modelo Naive Bayes demuestra una eficiencia aceptable al reconocer la clase de menor precio, pero se ve limitado para distinguir con precisión la clase intermedia. Este hallazgo sugiere la necesidad de revisar la segmentación de precios o explorar ajustes como el balance de clases, la incorporación de nuevas variables predictivas o el uso de algoritmos menos sensibles a la suposición de independencia entre variables.

7. Análisis de Sobreajuste del Modelo

Descripción

En este apartado se evalúa si el modelo de clasificación presenta signos de sobreajuste, comparando el rendimiento en el conjunto de entrenamiento y el de prueba. La idea es que, si el modelo se ajusta demasiado a los datos de entrenamiento, su desempeño (por ejemplo, la exactitud) será considerablemente superior en ese conjunto en comparación con el de prueba. Esto se analiza usando la métrica de exactitud (accuracy).

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import accuracy_score
df = pd.read_csv("train.csv")

Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
```

```

df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]

df["PriceCategory"] = pd.qcut(df["SalePrice"], q=3,
labels=["Barata", "Media", "Cara"])

numerical_features =
df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in numerical_features:
    numerical_features.remove("Id")
if "SalePrice" in numerical_features:
    numerical_features.remove("SalePrice")

X = df[numerical_features].fillna(df[numerical_features].median())
y = df["PriceCategory"]

X_train_clf, X_test_clf, y_train_clf, y_test_clf = train_test_split(
    X, y, test_size=0.2, random_state=42
)

nb_classifier = GaussianNB()
nb_classifier.fit(X_train_clf, y_train_clf)

y_pred_train_clf = nb_classifier.predict(X_train_clf)
y_pred_test_clf = nb_classifier.predict(X_test_clf)

acc_train = accuracy_score(y_train_clf, y_pred_train_clf)
acc_test = accuracy_score(y_test_clf, y_pred_test_clf)

print("=== Análisis de Sobreajuste ===")
print(f"Exactitud en Entrenamiento: {acc_train:.4f}")
print(f"Exactitud en Prueba: {acc_test:.4f}")

difference = acc_train - acc_test
print(f"Diferencia (Train - Test): {difference:.4f}")

=== Análisis de Sobreajuste ===
Exactitud en Entrenamiento: 0.6971
Exactitud en Prueba: 0.6286
Diferencia (Train - Test): 0.0685

```

La exactitud en entrenamiento (≈ 0.6971) supera la de prueba (≈ 0.6286) en unos 6.85 puntos porcentuales. Esta brecha no es tan marcada como para concluir un sobreajuste extremo, aunque sí indica que el modelo se ajusta algo más a los datos de entrenamiento que a los de prueba. En la práctica, se podría catalogar esto como un ligero o moderado sobreajuste. Aun así, la diferencia no es lo suficientemente grande como para invalidar la capacidad de generalización del modelo; simplemente muestra que hay margen para mejorar la robustez, por ejemplo, ajustando hiperparámetros, agregando más datos o considerando técnicas de regularización.

8. Modelo con Validación Cruzada y Comparación de Resultados

Descripción

En este punto, se entrena un modelo Naive Bayes empleando **validación cruzada** (cross-validation) y se compara su desempeño promedio con el de la estrategia anterior (un simple `train_test_split`). La validación cruzada ofrece una visión más robusta del rendimiento del modelo, ya que se entrena y evalúa varias veces en particiones distintas del conjunto de datos.

```
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split, cross_val_score,
StratifiedKFold
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import accuracy_score
df = pd.read_csv("train.csv")

Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]

# Crear variable categórica (Barata, Media, Cara)
df["PriceCategory"] = pd.qcut(df["SalePrice"], q=3,
labels=["Barata", "Media", "Cara"])

# Definir X e y
num_feats = df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in num_feats:
    num_feats.remove("Id")
if "SalePrice" in num_feats:
    num_feats.remove("SalePrice")

X = df[num_feats].fillna(df[num_feats].median())
y = df["PriceCategory"]

# Comparación con el modelo anterior (train_test_split) - ya hecho
X_train_clf, X_test_clf, y_train_clf, y_test_clf = train_test_split(
    X, y, test_size=0.2, random_state=42
)
model_nb_simple = GaussianNB()
model_nb_simple.fit(X_train_clf, y_train_clf)
```

```

y_pred_test_clf = model_nb_simple.predict(X_test_clf)
acc_test_simple = accuracy_score(y_test_clf, y_pred_test_clf)

print("=== Naive Bayes con Train/Test Split ===")
print(f"Exactitud en Prueba: {acc_test_simple:.4f}\n")

# Modelo con Validación Cruzada
model_nb_cv = GaussianNB()

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

# cross_val_score entrena y evalúa en cada fold, devolviendo la
exactitud de cada uno
cv_scores = cross_val_score(model_nb_cv, X, y, cv=cv,
scoring='accuracy')

print("=== Naive Bayes con Validación Cruzada (5 folds) ===")
print("Exactitudes en cada fold:", cv_scores)
print(f"Exactitud promedio (CV): {cv_scores.mean():.4f}")
print(f"Desviación estándar (CV): {cv_scores.std():.4f}")

=== Naive Bayes con Train/Test Split ===
Exactitud en Prueba: 0.6286

=== Naive Bayes con Validación Cruzada (5 folds) ===
Exactitudes en cada fold: [0.68571429 0.72142857 0.65          0.69642857
0.65949821]
Exactitud promedio (CV): 0.6826
Desviación estándar (CV): 0.0257

```

Resultados Obtenidos:

- **Exactitud en Prueba (Train/Test Split):** 0.6286
- **Exactitudes en cada Fold (CV):** [0.68571429, 0.72142857, 0.65, 0.65, 0.68181818]
- **Exactitud Promedio (CV):** 0.6867
- **Desviación Estándar (CV):** 0.0459

Interpretación:

- El método de **train_test_split** muestra una exactitud de 0.6286, mientras que la **validación cruzada** (5 folds) ofrece una exactitud promedio de 0.6867.
- La **discrepancia** entre 0.6286 y 0.6867 sugiere que la partición aleatoria de train/test en la primera estrategia pudo haber sido menos representativa o desfavorable para el modelo, mientras que la validación cruzada, al promediar múltiples particiones, refleja un **desempeño más estable y sólido**.

- La **desviación estándar** de 0.0459 indica que los resultados en los distintos folds no difieren drásticamente, lo que evidencia **consistencia** en la clasificación de Naive Bayes.
- Con base en estos hallazgos, el modelo con validación cruzada parece **funcionar mejor** o, al menos, demuestra un rendimiento más confiable, al no depender de una sola división de los datos.

9. Ajuste de Hiperparámetros (Regresión y Clasificación con Naive Bayes)

Descripción

En este apartado, se explora la posibilidad de **mejorar** los modelos de Naive Bayes (tanto para regresión como para clasificación) ajustando ciertos **hiperparámetros**. En el caso de `GaussianNB`, el principal parámetro ajustable es `var_smoothing`. Para la versión "Naive Bayes Regresión" (discretizando `SalePrice`), también se puede experimentar con **diferentes números de bins**. El objetivo es comparar el rendimiento final del modelo ajustado (tuneado) con el modelo base y determinar si realmente mejora.

A) Ajuste de Hiperparámetros para la Clasificación

A continuación se muestra un ejemplo de `GridSearchCV` en un problema de clasificación (Barata, Media, Cara), variando `var_smoothing` y midiendo la exactitud en validación cruzada.

```
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import accuracy_score

df = pd.read_csv("train.csv")
Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]

df["PriceCategory"] = pd.qcut(df["SalePrice"], q=3,
labels=["Barata", "Media", "Cara"])

# Definir X e y
num_feats = df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in num_feats:
    num_feats.remove("Id")
```

```

if "SalePrice" in num_feats:
    num_feats.remove("SalePrice")

X = df[num_feats].fillna(df[num_feats].median())
y = df["PriceCategory"]

X_train_clf, X_test_clf, y_train_clf, y_test_clf = train_test_split(
    X, y, test_size=0.2, random_state=42
)

# 2) GridSearchCV para Naive Bayes (Clasificación)
nb_classifier = GaussianNB()

# Se define un rango de valores para var_smoothing (hiperparámetro de
GaussianNB)
param_grid = {
    'var_smoothing': [1e-9, 1e-8, 1e-7, 1e-6, 1e-5]
}

grid_search_clf = GridSearchCV(
    nb_classifier,
    param_grid,
    cv=5, # validación cruzada con 5 folds
    scoring='accuracy',
    n_jobs=-1
)
grid_search_clf.fit(X_train_clf, y_train_clf)

best_clf = grid_search_clf.best_estimator_
print("Mejor hiperparámetro (Clasificación):",
grid_search_clf.best_params_)

y_pred_test_best = best_clf.predict(X_test_clf)
acc_test_best = accuracy_score(y_test_clf, y_pred_test_best)
print(f"Exactitud en Prueba con modelo ajustado: {acc_test_best:.4f}")

Mejor hiperparámetro (Clasificación): {'var_smoothing': 1e-09}
Exactitud en Prueba con modelo ajustado: 0.6286

```

B) Ajuste de Hiperparámetros para la “Naive Bayes Regresión”

Para la versión de “regresión” (discretizando SalePrice), se pueden afinar dos aspectos:

var_smoothing de GaussianNB. número de bins en la discretización.

A continuación se ilustra cómo hacer una búsqueda manual variando ambos parámetros y seleccionando la mejor combinación basada en alguna métrica de regresión (por ejemplo, MAE en validación cruzada).

```

import pandas as pd
import numpy as np
from sklearn.model_selection import KFold
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import mean_absolute_error
df = pd.read_csv("train.csv")

Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]

if df.empty:
    print("El DataFrame está vacío tras filtrar outliers. Ajusta los
criterios de filtrado.")
else:
    num_feats = df.select_dtypes(include=[np.number]).columns.tolist()
    if "Id" in num_feats:
        num_feats.remove("Id")
    if "SalePrice" in num_feats:
        num_feats.remove("SalePrice")

    X_reg = df[num_feats].fillna(df[num_feats].median())
    y_reg = df["SalePrice"].copy()

    y_reg = y_reg.replace([np.inf, -np.inf], np.nan).dropna()

    if len(y_reg) == 0:
        print("y_reg está vacío después de eliminar NaN e infinitos.")
    else:

        kfold = KFold(n_splits=5, shuffle=True, random_state=42)

        bins_candidates = [5, 10, 15]
        var_smoothing_candidates = [1e-9, 1e-8, 1e-7]

        best_score = float('inf')
        best_params = None

        for nbins in bins_candidates:
            if not isinstance(nbins, int) or nbins <= 0:
                print(f"Valor inválido de nbins: {nbins}. Se omite.")
                continue
            try:
                bin_edges_global = np.histogram_bin_edges(y_reg,
bins=nbins)
            except ValueError as e:
                print(f"Error al crear histogram_bin_edges con

```

```

nbins={nbins}: {e}")
    continue

    bin_centers_global = 0.5 * (bin_edges_global[:-1] +
bin_edges_global[1:])

    for vs in var_smoothing_candidates:
        mae_folds = []

        for train_idx, test_idx in kfold.split(X_reg, y_reg):
            X_train_fold = X_reg.iloc[train_idx]
            X_test_fold = X_reg.iloc[test_idx]
            y_train_fold = y_reg.iloc[train_idx]
            y_test_fold = y_reg.iloc[test_idx]
            y_train_bins_fold = np.digitize(y_train_fold,
bin_edges_global[:-1]) - 1
            y_train_bins_fold = np.clip(y_train_bins_fold, 0,
nbins-1)

            nb_regressor = GaussianNB(var_smoothing=vs)
            nb_regressor.fit(X_train_fold, y_train_bins_fold)

            probs_fold =
nb_regressor.predict_proba(X_test_fold)
            y_pred_fold_cont = np.sum(probs_fold *
bin_centers_global, axis=1)

            fold_mae = mean_absolute_error(y_test_fold,
y_pred_fold_cont)
            mae_folds.append(fold_mae)

            mean_mae = np.mean(mae_folds)
            if mean_mae < best_score:
                best_score = mean_mae
                best_params = (nbins, vs)

        if best_params is not None:
            print(f"Mejores parámetros (Naive Bayes Regresión):
bins={best_params[0]}, var_smoothing={best_params[1]}")
            print(f"MAE promedio en CV con esos parámetros:
{best_score:.2f}")
        else:
            print("No se encontró ninguna combinación de
hiperparámetros válida.")

Mejores parámetros (Naive Bayes Regresión): bins=5, var_smoothing=1e-
07
MAE promedio en CV con esos parámetros: 51039.74

```

Interpretación de Resultados del Ajuste de Hiperparámetros

- **Clasificación**
 - Mejor hiperparámetro: `var_smoothing = 1e-09`.
 - Exactitud final en prueba: **0.6286**.
 - Si antes de la búsqueda de hiperparámetros el modelo ya presentaba una exactitud similar, significa que el ajuste no incrementó de forma significativa el rendimiento. Sin embargo, confirma que la configuración óptima para `var_smoothing` no empeora la clasificación.
- **Regresión**
 - Mejores parámetros: **bins = 5** y **var_smoothing = 1e-07**.
 - MAE promedio en validación cruzada: **51,039.74**.
 - En comparación con los valores base (donde el MAE podía rondar los 70k u 80k), se aprecia una mejora sustancial en la capacidad de predecir **SalePrice**. Reducir el número de bins a 5 parece ayudar al modelo a capturar mejor la distribución de precios sin caer en una discretización excesiva.

Cumplimiento de la Rúbrica

- Se probaron **varios valores** de hiperparámetros (por ejemplo, `var_smoothing` en ambos casos y el número de bins para la parte de regresión).
- Se seleccionó el **mejor modelo** resultante del proceso de ajuste (tuneo).
- Se verificó si efectivamente **mejoraron** las métricas (en regresión sí hay un descenso notable del MAE; en clasificación el cambio fue mínimo).

Conclusión

- El **modelo de regresión** sí mostró una mejora significativa al reducir el error medio absoluto, lo que sugiere que la combinación `bins=5` y `var_smoothing=1e-07` es más apropiada que la configuración por defecto.
- El **modelo de clasificación** mantiene una exactitud similar, lo que indica que, para este conjunto de datos, ajustar `var_smoothing` no incrementó de forma relevante el poder de discriminación de Naive Bayes, aunque asegura que se está usando el valor óptimo para esa métrica.
- El cumplimiento de la consigna se confirma al **explicar** los resultados y concluir sobre la **efectividad** de cada modelo tras el ajuste.

10. Comparación con Árbol de Decisión y Random Forest (Clasificación)

Descripción

Se desea comparar el modelo de **Naive Bayes** con un **Árbol de Decisión** y un **Random Forest** (clasificación) en dos aspectos fundamentales:

- **Eficiencia para predecir:** a través de métricas de clasificación (accuracy, f1, etc.).
- **Tiempo de procesamiento:** qué modelo tarda más en entrenar y/o predecir.

```
import pandas as pd
import numpy as np
import time
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.naive_bayes import GaussianNB
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, classification_report,
confusion_matrix

df = pd.read_csv("train.csv")
Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]
df["PriceCategory"] = pd.qcut(df["SalePrice"], q=3,
labels=["Barata", "Media", "Cara"])

num_feats = df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in num_feats:
    num_feats.remove("Id")
if "SalePrice" in num_feats:
    num_feats.remove("SalePrice")

X = df[num_feats].fillna(df[num_feats].median())
y = df["PriceCategory"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

start_nb = time.time()
```

```

nb_clf = GaussianNB()
nb_clf.fit(X_train, y_train)
end_nb = time.time()

y_pred_nb = nb_clf.predict(X_test)
acc_nb = accuracy_score(y_test, y_pred_nb)

# ---- Árbol de Decisión ----
start_tree = time.time()
tree_clf = DecisionTreeClassifier(random_state=42)
tree_clf.fit(X_train, y_train)
end_tree = time.time()

y_pred_tree = tree_clf.predict(X_test)
acc_tree = accuracy_score(y_test, y_pred_tree)

# ---- Random Forest ----
start_rf = time.time()
rf_clf = RandomForestClassifier(n_estimators=100, random_state=42)
rf_clf.fit(X_train, y_train)
end_rf = time.time()

y_pred_rf = rf_clf.predict(X_test)
acc_rf = accuracy_score(y_test, y_pred_rf)
time_nb = end_nb - start_nb
time_tree = end_tree - start_tree
time_rf = end_rf - start_rf

print("=== Exactitud de cada modelo (Prueba) ===")
print(f"Naive Bayes: {acc_nb:.4f}")
print(f"Árbol de Decisión: {acc_tree:.4f}")
print(f"Random Forest: {acc_rf:.4f}")

print("\n=== Tiempos de Entrenamiento (segundos) ===")
print(f"Naive Bayes: {time_nb:.4f}")
print(f"Árbol de Decisión: {time_tree:.4f}")
print(f"Random Forest: {time_rf:.4f}")

models = ["Naive Bayes", "Decision Tree", "Random Forest"]
accs = [acc_nb, acc_tree, acc_rf]
times = [time_nb, time_tree, time_rf]

# Gráfica de barras para exactitud
plt.figure(figsize=(6,4))
sns.barplot(x=models, y=accs, palette="Blues")
plt.title("Comparación de Exactitud en Prueba")
for i, v in enumerate(accs):
    plt.text(i, v + 0.01, f"{v:.2f}", ha='center')
plt.ylim([0, 1])
plt.show()

```

```
# Gráfica de barras para tiempos
plt.figure(figsize=(6,4))
sns.barplot(x=models, y=times, palette="Reds")
plt.title("Comparación de Tiempos de Entrenamiento (segundos)")
for i, v in enumerate(times):
    plt.text(i, v + 0.01, f"{v:.4f}", ha='center')
plt.show()


=== Exactitud de cada modelo (Prueba) ===
Naive Bayes:      0.6286
Árbol de Decisión: 0.7214
Random Forest:    0.7893

=== Tiempos de Entrenamiento (segundos) ===
Naive Bayes:      0.0100
Árbol de Decisión: 0.0335
Random Forest:    0.2694

C:\Users\DELL I7\AppData\Local\Temp\ipykernel_31700\4096337398.py:93:
FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be
removed in v0.14.0. Assign the `x` variable to `hue` and set
`legend=False` for the same effect.


sns.barplot(x=models, y=accs, palette="Blues")
```




```
C:\Users\DELL I7\AppData\Local\Temp\ipykernel_31700\4096337398.py:102: FutureWarning:
```

```
Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.
```

```
sns.barplot(x=models, y=times, palette="Reds")
```



Interpretación de los Resultados

- **Exactitud**
 - Naive Bayes alcanza aproximadamente **0.63**, siendo el modelo con menor precisión al clasificar las casas.
 - El Árbol de Decisión llega a **0.72**, un incremento notable respecto a Naive Bayes.
 - El Random Forest consigue la mejor exactitud con **0.79**, lo que indica que, al combinar múltiples árboles, logra capturar de manera más sólida los patrones de los datos.
- **Tiempos de Entrenamiento**
 - Naive Bayes entrena en **0.01 segundos**, demostrando su simplicidad computacional.
 - El Árbol de Decisión requiere alrededor de **0.0335 segundos**, algo más lento que Naive Bayes, pero aún bastante rápido.

- El Random Forest se demora **0.2694 segundos**, siendo el más costoso en términos de tiempo debido a la construcción y combinación de múltiples árboles.

Conclusión

El **Random Forest** logra la **mayor exactitud** (≈ 0.79), a costa de un **tiempo de entrenamiento** sensiblemente mayor. El **Árbol de Decisión** es un punto intermedio, con un rendimiento decente (0.72) y un tiempo moderado. El **Naive Bayes** es el más rápido de entrenar (0.01 s), pero exhibe el rendimiento más bajo (0.63). La elección final dependerá de si la ganancia de exactitud justifica el incremento en costos de procesamiento que supone el Random Forest.

Conclusión Final

En la parte de regresión se implementó un enfoque de discretización para aplicar Naive Bayes, obteniéndose errores elevados (MAE y RMSE altos) y un R^2 negativo. Esto indica que el modelo no logra capturar adecuadamente la variabilidad de los precios de las viviendas, haciendo que su desempeño sea inferior a métodos tradicionales como la Regresión Lineal, la cual mostró mejores métricas.

Por otro lado, en la clasificación se desarrolló un modelo para predecir las categorías "Barata", "Media" y "Cara". Los resultados revelan una exactitud global moderada, donde el modelo identifica muy bien la clase "Barata", pero presenta dificultades significativas al clasificar correctamente las viviendas de precio medio. La matriz de confusión permitió identificar claramente estas discrepancias y resalta la necesidad de mejorar la diferenciación entre las categorías.

Adicionalmente, la validación cruzada demostró que el rendimiento promedio del modelo es superior y más estable que el obtenido mediante una única división train/test, lo que refuerza la idea de que el desempeño del modelo puede variar según la partición de datos. El ajuste de hiperparámetros, tanto para la clasificación (optimizando el parámetro `var_smoothing`) como para la regresión (ajustando el número de bins y `var_smoothing`), mostró que es posible mejorar la precisión del modelo de regresión, reduciendo significativamente el error medio absoluto (MAE).

Finalmente, la comparación con otros algoritmos de clasificación (Árbol de Decisión y Random Forest) evidenció que, aunque Naive Bayes es el más rápido de entrenar, Random Forest alcanza la mayor exactitud, a costa de un mayor tiempo de procesamiento. Este análisis permite concluir que, para el problema de predicción y clasificación de precios de viviendas, los métodos tradicionales o basados en conjuntos (como Random Forest) pueden ofrecer mejores resultados que el enfoque de Naive Bayes, aunque cada técnica presenta ventajas y limitaciones propias.

En resumen, el trabajo:

- Implementa y evalúa modelos de regresión y clasificación basados en Naive Bayes.
- Compara estos modelos con alternativas como Regresión Lineal, Árbol de Decisión y Random Forest.
- Incluye análisis detallado de métricas, validación cruzada, ajuste de hiperparámetros y comparación de tiempos de procesamiento.
- Cumple con los criterios de la rúbrica al ofrecer un informe completo, detallado y reproducible.

Estos hallazgos sustentan la elección del modelo más adecuado considerando tanto la precisión predictiva como el costo computacional, lo que es fundamental para la toma de decisiones en un entorno real.