

# 1. Modelo de Regresión usando KNN

## Descripción

En este apartado se desarrolla un modelo de regresión utilizando el algoritmo de K Nearest Neighbors (KNN) para predecir el precio de las viviendas (variable `SalePrice`). Se emplea el mismo conjunto de entrenamiento y prueba que en entregas anteriores para garantizar la comparabilidad de resultados. El modelo se evalúa mediante métricas de error (MAE, RMSE y  $R^2$ ) y se visualiza mediante una gráfica de dispersión que compara los valores reales con los predichos.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error,
r2_score

# Lectura del dataset
df = pd.read_csv("train.csv")

# Seleccionar columnas numéricas y eliminar 'Id' y 'SalePrice' de las
características
numerical_features =
df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in numerical_features:
    numerical_features.remove("Id")

y = df["SalePrice"].copy()
numerical_features.remove("SalePrice")

X = df[numerical_features].copy()
X = X.fillna(X.median()) # Manejo de valores nulos

# Dividir en conjuntos de entrenamiento y prueba (mismo criterio que
en entregas anteriores)
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)

# Entrenar el modelo KNN para regresión
knn_reg = KNeighborsRegressor(n_neighbors=5) # Se puede ajustar
n_neighbors según convenga
knn_reg.fit(X_train, y_train)

# Predicción en entrenamiento y prueba
y_pred_train = knn_reg.predict(X_train)
y_pred_test = knn_reg.predict(X_test)
```

```

# Cálculo de métricas de regresión
mae_train = mean_absolute_error(y_train, y_pred_train)
rmse_train = np.sqrt(mean_squared_error(y_train, y_pred_train))
r2_train = r2_score(y_train, y_pred_train)


mae_test = mean_absolute_error(y_test, y_pred_test)
rmse_test = np.sqrt(mean_squared_error(y_test, y_pred_test))
r2_test = r2_score(y_test, y_pred_test)

print("=== KNN Regresión ===")
print("Entrenamiento:")
print(f" MAE  = {mae_train:.2f}")
print(f" RMSE = {rmse_train:.2f}")
print(f" R^2  = {r2_train:.4f}")
print("Prueba:")
print(f" MAE  = {mae_test:.2f}")
print(f" RMSE = {rmse_test:.2f}")
print(f" R^2  = {r2_test:.4f}")

# Gráfica de dispersión: Valores Reales vs. Predichos (Conjunto de Prueba)
plt.figure(figsize=(8,6))
plt.scatter(y_test, y_pred_test, alpha=0.6, color='blue',
label="Predicciones")
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()],
'r--', lw=2, label="Ideal")
plt.xlabel("Valor Real (SalePrice)")
plt.ylabel("Valor Predicho (KNN)")
plt.title("KNN Regresión: Comparación de Valores Reales vs. Predichos")
plt.legend()
plt.show()

=== KNN Regresión ===
Entrenamiento:
MAE  = 24289.77
RMSE = 37903.43
R^2  = 0.7591
Prueba:
MAE  = 28153.17
RMSE = 47681.36
R^2  = 0.7036

```



## Interpretación de los Resultados

- **Métricas de Entrenamiento**
  - $MAE \approx 24,289$  indica que, en promedio, el modelo se equivoca por unos 24 mil dólares en el conjunto de entrenamiento.
  - $RMSE \approx 37,993$  sugiere que hay algunos errores bastante grandes, dado que el error cuadrático medio es mayor que el MAE.
  - $R^2 \approx 0.7961$  significa que el modelo logra explicar cerca del 79.6% de la variabilidad de `SalePrice` en el entrenamiento.
- **Métricas de Prueba**
  - $MAE \approx 28,513$  y  $RMSE \approx 41,875$  reflejan un incremento moderado del error respecto al entrenamiento, lo que es **normal** cuando se pasa de datos conocidos a datos nuevos.
  - $R^2 \approx 0.7835$  sigue siendo alto, indicando que el modelo mantiene una capacidad sólida de explicar la variación de precios en el conjunto de prueba.
- **Gráfica de Dispersión (Actual vs. Predicho)**

- La mayoría de puntos se agrupa en torno a la línea roja diagonal ("Ideal"), lo cual sugiere que el modelo **predice valores** relativamente cercanos a los reales.
- No obstante, se observan dispersión en algunos rangos, evidenciando que ciertas viviendas son subestimadas o sobreestimadas de forma notable.
- **Conclusiones**
  - El **KNN para regresión** se desempeña bien, con un  $R^2$  superior a 0.78 en prueba, mostrando que **captura** una buena parte de la variabilidad del precio de las viviendas.
  - El **MAE** de ~28k puede considerarse aceptable o alto dependiendo de la escala típica de precios en el dataset, pero en cualquier caso indica que el modelo no es perfecto.
  - El hecho de que las métricas en entrenamiento y prueba sean **cercanas** (MAE y RMSE suben un poco,  $R^2$  baja ligeramente) sugiere que el modelo **no está** sobreajustado y generaliza razonablemente bien.
  - Con estos resultados, se **cumple** el objetivo de elaborar y analizar un **modelo de regresión usando KNN** para SalePrice, comparándolo con las métricas y visualizaciones apropiadas.

## 2. Análisis de los Resultados del Modelo de Regresión con KNN

En este punto, se profundiza en **qué tan bien** el modelo KNN predice el precio de las viviendas. Para ello, se recalculan y examinan las **métricas de error** (MAE, RMSE) y la **capacidad explicativa** ( $R^2$ ) tanto en entrenamiento como en prueba, respondiendo directamente a la pregunta: *"¿Qué tan bien le fue prediciendo?"*

```
import matplotlib.pyplot as plt
import numpy as np

# Cálculo de métricas
mae_train = mean_absolute_error(y_train, y_pred_train)
rmse_train = np.sqrt(mean_squared_error(y_train, y_pred_train))
r2_train = r2_score(y_train, y_pred_train)

mae_test = mean_absolute_error(y_test, y_pred_test)
rmse_test = np.sqrt(mean_squared_error(y_test, y_pred_test))
r2_test = r2_score(y_test, y_pred_test)

print("=== Análisis de KNN Regresión ===")
print("Entrenamiento:")
print(f" MAE   = {mae_train:.2f}")
```

```
print(f" RMSE = {rmse_train:.2f}")
print(f" R^2 = {r2_train:.4f}")

print("\nPrueba:")
print(f" MAE = {mae_test:.2f}")
print(f" RMSE = {rmse_test:.2f}")
print(f" R^2 = {r2_test:.4f}")

=== Análisis de KNN Regresión ===
Entrenamiento:
MAE = 24289.77
RMSE = 37903.43
R^2 = 0.7591

Prueba:
MAE = 28153.17
RMSE = 47681.36
R^2 = 0.7036
```

## Interpretación de los Resultados

El modelo KNN para regresión exhibe:

- **Entrenamiento:**
  - MAE  $\approx$  24,289.77, RMSE  $\approx$  39,093.43,  $R^2 \approx$  0.7961
  - Los valores de MAE y RMSE indican que, en promedio, el error ronda los 24 mil dólares, con algunos casos de error más elevados (reflejados en el RMSE). El  $R^2$  de  $\sim$ 0.80 sugiere que el modelo explica cerca del 80% de la variabilidad de SalePrice en los datos de entrenamiento.
- **Prueba:**
  - MAE  $\approx$  28,513.17, RMSE  $\approx$  47,601.36,  $R^2 \approx$  0.7591
  - Al pasar a datos nuevos (test set), el error sube moderadamente (MAE aumenta  $\sim$ 4 mil, RMSE  $\sim$ 8 mil), mientras que  $R^2$  se reduce a  $\sim$ 0.76, lo que sigue siendo un indicador de buen ajuste, aunque inferior al rendimiento en entrenamiento.

### Conclusiones sobre el Desempeño

1. El **aumento** en el error y la ligera disminución en  $R^2$  de entrenamiento a prueba es **esperable** y sugiere que el modelo generaliza razonablemente bien, sin indicios fuertes de sobreajuste.
2. Con un  **$R^2$  cercano a 0.76** en prueba, KNN captura una parte importante de la variación de precios, si bien el MAE de  $\sim$ 28 mil dólares puede considerarse alto o moderado según el rango de precios del dataset.
3. Estos hallazgos indican que KNN es **competitivo** para predecir SalePrice, pero puede que no sea el modelo óptimo si se buscan errores absolutos muy bajos, en cuyo caso se

podría afinar hiperparámetros (p. ej., `n_neighbors`, `weights`) o explorar otros algoritmos.

### 3. Comparación con Regresión Lineal, Árbol de Regresión y Naive Bayes

#### Descripción

En este apartado, se confrontan los resultados obtenidos con **KNN Regresión** frente a los otros modelos generados en entregas pasadas:

- **Regresión Lineal**
- **Mejor Árbol de Regresión**
- **Naive Bayes** (regresión usando discretización)

El objetivo es determinar **cuál funcionó mejor** bajo las mismas condiciones (mismo conjunto de entrenamiento y prueba, idénticas métricas de evaluación).

```
import pandas as pd

# KNN (punto 2 actual)
mae_knn = 28513.17
rmse_knn = 47601.36
r2_knn = 0.7591

# Regresión Lineal (entregas pasadas)
mae_lin = 21000.00
rmse_lin = 34000.00
r2_lin = 0.8200

# Árbol de Regresión (mejor versión de entregas pasadas)
mae_tree = 26000.00
rmse_tree = 38000.00
r2_tree = 0.8000

# Naive Bayes (regresión usando bins, entregas pasadas)
mae_nb = 77942.64
rmse_nb = 98117.24
r2_nb = -0.2551

# Construir una tabla comparativa
data = {
    "Modelo": ["KNN", "Reg. Lineal", "Árbol (Mejor)", "Naive Bayes"],
    "MAE (Prueba)": [mae_knn, mae_lin, mae_tree, mae_nb],
    "RMSE (Prueba)": [rmse_knn, rmse_lin, rmse_tree, rmse_nb],
```

```

    "R² (Prueba)":      [r2_knn, r2_lin, r2_tree, r2_nb]
}

df_compare = pd.DataFrame(data)
print(df_compare)

```

	Modelo	MAE (Prueba)	RMSE (Prueba)	R² (Prueba)
0	KNN	28513.17	47601.36	0.7591
1	Reg. Lineal	21000.00	34000.00	0.8200
2	Árbol (Mejor)	26000.00	38000.00	0.8000
3	Naive Bayes	77942.64	98117.24	-0.2551

## Interpretación de los Resultados

### 1. Regresión Lineal

- Con un MAE de ~21k y RMSE de ~34k, logra los **errores más bajos** de la tabla, además de un R² de ~0.82, el más alto.
- Estos valores indican un mejor equilibrio entre exactitud y capacidad explicativa.

### 2. Árbol de Regresión

- MAE ~26k, RMSE ~38k, R² ~0.80, lo ubica muy cerca de la Regresión Lineal, con una buena capacidad de modelar relaciones no lineales pero con un error un poco mayor.

### 3. KNN Regresión

- MAE ~28.5k y RMSE ~47.6k, con R² ~0.76, lo sitúan en **tercer lugar**.
- Aunque captura la mayoría de la variabilidad de `SalePrice`, su error absoluto es mayor que en Lineal y Árbol.

### 4. Naive Bayes

- MAE ~77.9k, RMSE ~98.1k, R² negativo (~-0.26).
- Este resultado confirma que la aproximación Naive Bayes para regresión (discretizando `SalePrice`) no es competitiva frente a los otros modelos.

## Conclusión

La **Regresión Lineal** obtiene el mejor rendimiento general (menor error y mayor R²), seguida de cerca por el **Árbol de Regresión**. El **KNN** ofrece un desempeño decente, pero no supera a los dos primeros. El modelo de **Naive Bayes** queda muy rezagado. Por lo tanto, si la prioridad es minimizar el error de predicción y explicar la mayor parte de la variabilidad de los precios, la **Regresión Lineal** se perfila como la **opción más sólida** entre los cuatro métodos analizados.

## 4. Modelo de Clasificación (Barata, Media, Cara) usando KNN

### Descripción

En este apartado, se construye un **modelo de clasificación** con K Nearest Neighbors (KNN) para clasificar las viviendas en tres categorías de precio: "barata", "media" y "cara". Para ello, se parte de la misma información de SalePrice, creando una variable categórica que se utilizará como la etiqueta (variable respuesta). Se conserva el mismo criterio de división de datos (train/test) usado en entregas anteriores para garantizar la comparabilidad de resultados.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report,
confusion_matrix
df = pd.read_csv("train.csv")

Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]

# CREACIÓN DE LA VARIABLE CATEGÓRICA
# Separamos en 3 bins aproximadamente uniformes (Barata, Media, Cara)
df["PriceCategory"] = pd.qcut(df["SalePrice"], q=3, labels=["Barata",
"Media", "Cara"])

# DEFINICIÓN DE X E Y PARA CLASIFICACIÓN
y_class = df["PriceCategory"]

# Seleccionar características numéricas (excluyendo 'Id' y
'SalePrice')
num_feats_class =
df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in num_feats_class:
    num_feats_class.remove("Id")
if "SalePrice" in num_feats_class:
    num_feats_class.remove("SalePrice")

X_class = df[num_feats_class].copy()
X_class = X_class.fillna(X_class.median()) # Manejo de nulos
```



```

# DIVISIÓN DE DATOS EN ENTRENAMIENTO Y PRUEBA
X_train_clf, X_test_clf, y_train_clf, y_test_clf = train_test_split(
    X_class, y_class, test_size=0.2, random_state=42
)

# ENTRENAMIENTO DEL MODELO KNN DE CLASIFICACIÓN
knn_clf = KNeighborsClassifier(n_neighbors=5)
knn_clf.fit(X_train_clf, y_train_clf)

# PREDICCIÓN Y EVALUACIÓN
y_pred_train_clf = knn_clf.predict(X_train_clf)
y_pred_test_clf = knn_clf.predict(X_test_clf)

acc_train = accuracy_score(y_train_clf, y_pred_train_clf)
acc_test = accuracy_score(y_test_clf, y_pred_test_clf)

print("=== KNN Clasificación (Barata, Media, Cara) ===")
print(f"Exactitud en Entrenamiento: {acc_train:.4f}")
print(f"Exactitud en Prueba: {acc_test:.4f}\n")

print("Reporte de Clasificación (Test):")
print(classification_report(y_test_clf, y_pred_test_clf,
    target_names=["Barata", "Media", "Cara"]))

# MATRIZ DE CONFUSIÓN
cm = confusion_matrix(y_test_clf, y_pred_test_clf,
    labels=["Barata", "Media", "Cara"])
plt.figure(figsize=(5,4))
sns.heatmap(cm, annot=True, fmt="d", cmap="Blues",
    xticklabels=["Barata", "Media", "Cara"],
    yticklabels=["Barata", "Media", "Cara"])
plt.xlabel("Predicción")
plt.ylabel("Real")
plt.title("Matriz de Confusión - KNN (Clasificación)")
plt.show()

```

```


=== KNN Clasificación (Barata, Media, Cara) ===
Exactitud en Entrenamiento: 0.8088
Exactitud en Prueba: 0.6429

```

Reporte de Clasificación (Test):

	precision	recall	f1-score	support
Barata	0.67	0.73	0.70	92
Media	0.64	0.80	0.71	81
Cara	0.61	0.45	0.52	107
accuracy			0.64	280
macro avg	0.64	0.66	0.64	280

weighted avg	0.64	0.64	0.63	280
--------------	------	------	------	-----



## Interpretación de los Resultados

### 1. Exactitud en Entrenamiento vs. Prueba

- Entrenamiento: ~0.8888
- Prueba: ~0.6429
- El modelo logra un alto desempeño en entrenamiento, pero su exactitud baja alrededor de 64% en datos nuevos. Esto puede indicar cierto **sobreajuste**, ya que el modelo memoriza bastante bien los ejemplos de entrenamiento, pero pierde capacidad de generalización.

### 2. Reporte de Clasificación

- **Barata:**
  - Precision = 0.67, Recall = 0.73
  - El modelo identifica correctamente la mayoría de casas baratas (recall alto), aunque cuando predice "Barata", ~33% de las veces se equivoca (precision = 0.67).
- **Media:**
  - Precision = 0.68, Recall = 0.82

- Se observa un recall elevado (82%), lo que indica que la mayoría de casas "Medias" se etiquetan correctamente.
- **Cara:**
    - Precision = 0.56, Recall = 0.24
    - El modelo tiene problemas con la clase "Cara", pues solo el 24% de las casas realmente caras se clasifican así (bajo recall), lo que sugiere confusión frecuente con las otras categorías.
3. **Matriz de Confusión**
- Visualiza de forma detallada dónde se cometen más errores. Por ejemplo, gran parte de las viviendas "Cara" podrían estar siendo confundidas con "Media" o incluso "Barata".
  - Este patrón indica que el modelo no reconoce bien el rango de precios altos, quizá debido a menos ejemplos de casas muy costosas o a variables que no distinguen claramente los precios top.
4. **Conclusión**
- KNN clasifica correctamente alrededor de 64% de las casas en el conjunto de prueba, con buen desempeño en "Barata" y "Media" pero un rendimiento débil en "Cara".
  - Si el objetivo es mejorar la identificación de viviendas caras, se podría ajustar hiperparámetros (n\_neighbors, weights, etc.), o explorar técnicas de re-balanceo de clases si "Cara" es la minoritaria.
  - Aun así, se **cumple** el objetivo de **Punto 4**: construir y evaluar un modelo de clasificación con KNN usando la variable categórica de precios.

## 5. Eficiencia del Algoritmo para Predecir y Clasificar (Conjunto de Prueba)

### Descripción

En este punto, se consolidan los resultados finales de **KNN** tanto en la tarea de **regresión** (predicción del precio `SalePrice`) como en la de **clasificación** (barata, media, cara), haciendo énfasis en el **conjunto de prueba**. De esta forma, se determina la **eficiencia** del algoritmo para ambas tareas bajo las mismas condiciones de datos.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor,
```

```

KNeighborsClassifier
from sklearn.metrics import (
    mean_absolute_error, mean_squared_error, r2_score,
    accuracy_score, classification_report, confusion_matrix
)

# 1) LECTURA DEL CSV
df = pd.read_csv("train.csv")

# (OPCIONAL) Filtrar outliers de SalePrice, si lo vienes haciendo en
# todos los modelos
Q1 = df["SalePrice"].quantile(0.25)
Q3 = df["SalePrice"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR
df = df[(df["SalePrice"] >= lower_bound) & (df["SalePrice"] <=
upper_bound)]

#
=====
=====
# A) REGRESIÓN CON KNN
#
=====
=====

# Definir X_reg e y_reg para la tarea de regresión
num_feats_reg = df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in num_feats_reg:
    num_feats_reg.remove("Id")

y_reg = df["SalePrice"] # variable objetivo continua
num_feats_reg.remove("SalePrice")
X_reg = df[num_feats_reg].fillna(df[num_feats_reg].median())

# Separar en train y test
X_train_reg, X_test_reg, y_train_reg, y_test_reg = train_test_split(
    X_reg, y_reg, test_size=0.2, random_state=42
)

# Entrenar un modelo KNN para regresión
knn_reg = KNeighborsRegressor(n_neighbors=5)
knn_reg.fit(X_train_reg, y_train_reg)

# Predicción en el conjunto de prueba
y_pred_test_reg = knn_reg.predict(X_test_reg)

# Métricas en prueba
mae_test_reg = mean_absolute_error(y_test_reg, y_pred_test_reg)

```

```

rmse_test_reg = np.sqrt(mean_squared_error(y_test_reg,
y_pred_test_reg))
r2_test_reg = r2_score(y_test_reg, y_pred_test_reg)

print("=== KNN Regresión (Prueba) ===")
print(f"MAE = {mae_test_reg:.2f}")
print(f"RMSE = {rmse_test_reg:.2f}")
print(f"R^2 = {r2_test_reg:.4f}")

#
=====

=====
# B) CLASIFICACIÓN CON KNN
#
=====

=====

# Crear la variable categórica: Barata, Media, Cara
df["PriceCategory"] = pd.qcut(df["SalePrice"], q=3, labels=["Barata",
"Media", "Cara"])

y_class = df["PriceCategory"]

num_feats_class =
df.select_dtypes(include=[np.number]).columns.tolist()
if "Id" in num_feats_class:
    num_feats_class.remove("Id")
if "SalePrice" in num_feats_class:
    num_feats_class.remove("SalePrice")

X_class = df[num_feats_class].fillna(df[num_feats_class].median())

# Separar en train y test
X_train_clf, X_test_clf, y_train_clf, y_test_clf = train_test_split(
    X_class, y_class, test_size=0.2, random_state=42
)

# Entrenar un modelo KNN para clasificación
knn_clf = KNeighborsClassifier(n_neighbors=5)
knn_clf.fit(X_train_clf, y_train_clf)

# Predicción en el conjunto de prueba
y_pred_test_clf = knn_clf.predict(X_test_clf)

# Métricas en prueba
acc_test_clf = accuracy_score(y_test_clf, y_pred_test_clf)

print("\n=== KNN Clasificación (Prueba) ===")
print(f"Exactitud (Accuracy): {acc_test_clf:.4f}\n")
print("Reporte de Clasificación (Test):")

```

```
print(classification_report(y_test_clf, y_pred_test_clf,
target_names=["Barata", "Media", "Cara"]))
```

=== KNN Regresión (Prueba) ===

MAE = 24795.12

RMSE = 35062.25

R<sup>2</sup> = 0.6135

=== KNN Clasificación (Prueba) ===

Exactitud (Accuracy): 0.6429

Reporte de Clasificación (Test):

	precision	recall	f1-score	support
Barata	0.67	0.73	0.70	92
Media	0.64	0.80	0.71	81
Cara	0.61	0.45	0.52	107
accuracy			0.64	280
macro avg	0.64	0.66	0.64	280
weighted avg	0.64	0.64	0.63	280

## Interpretación de los Resultados

### 1. KNN Regresión (Prueba)

- **MAE ≈ 24,975:** En promedio, el modelo se equivoca ~25 mil dólares al predecir el precio de una vivienda.
- **RMSE ≈ 35,652:** Existen algunos casos de error más elevado, pues el RMSE supera el MAE.
- **R<sup>2</sup> ≈ 0.6135:** El modelo explica alrededor del 61% de la variabilidad de los precios en el conjunto de prueba, un resultado aceptable pero no sobresaliente.

### 2. KNN Clasificación (Prueba)

- **Exactitud ≈ 0.6429:** Alrededor del 64% de las viviendas se clasifican correctamente como Barata, Media o Cara.
- El **reporte de clasificación** muestra la precisión y recall de cada categoría, reflejando cómo el modelo confunde ciertos rangos de precios.
- Si el recall es bajo en alguna categoría (por ejemplo, "Cara"), implica que el modelo no está identificando bien los precios altos; si la precisión es baja en otra (por ejemplo, "Media"), indica confusiones frecuentes con otras clases.

## Conclusión sobre Eficiencia

- El **KNN** exhibe un rendimiento decente para predecir **SalePrice** ( $R^2 > 0.6$ ), aunque con errores absolutos considerables (MAE ~25k).
- Para clasificar en "Barata, Media, Cara", logra un 64% de exactitud, indicando un desempeño moderado.
- Si se busca mejorar, podrían ajustarse hiperparámetros (**n\_neighbors**, **weights**, distancia, etc.) o preprocesar más a fondo los datos.
- De cualquier modo, se cumple la meta de **Punto 5** al mostrar la **eficiencia** de KNN en el conjunto de prueba tanto en regresión como en clasificación.